

Introducción a la simulación de variables aleatorias

Contents

1 Simulación del lanzamiento de un dado	1
2 Simulación de una variable normal	1
3 Simulación de modelos de regresión	4
3.1 Simulación de valores condicionados	4
3.2 Simulación de conjuntos de puntos	7

1 Simulación del lanzamiento de un dado

2 Simulación de una variable normal


Sea la variable aleatoria $X \sim N(\mu, \sigma)$. Cuando simulamos una variable con R, la probabilidad de que la variable X tome un valor en un intervalo concreto $[x_i, x_j]$ es proporcional al valor del área de la función de densidad evaluada entre los puntos x_i y x_j . Es decir:

$$P(X \in [x_i, x_j]) = k \int_{x_i}^{x_j} f(x) dx$$

donde k es una constante y $f(x_j) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2\sigma^2}(x_j - \mu)^2\right)$.

Por ejemplo, vamos a analizar la variable $X \sim N(3, 1)$:

```
curve(dnorm(x, mean = 3, sd = 1), from = -2, to = 8, col = "blue", lwd = 2)
```



Cuando generamos valores aleatorios de la variable X , lo más probable será obtener valores entre 2 y 4, y será menos frecuente obtener valores entre 0 y 2 y entre 4 y 6. Veamos un ejemplo:

```
set.seed(123)
(x = round(rnorm(20, 3, 1), 2) )
```

```
## [1] 2.44 2.77 4.56 3.07 3.13 4.72 3.46 1.73 2.31 2.55 4.22 3.36 3.40 3.11 2.44 4.79 3.50 1.03 3.70 2.12
```


```
table(cut(x, breaks = -2:8))
```

```
##
## (-2,-1] (-1,0] (0,1] (1,2] (2,3] (3,4] (4,5] (5,6] (6,7] (7,8]
##      0      0      0      2      6      8      4      0      0      0
```

Por tanto, el histograma de los numeros aleatorios deberá parecerse a la función de densidad simulada:

```
hist(x, breaks = -2:8, freq = F)
curve(dnorm(x, mean = 3, sd = 1), col = "blue", lwd = 2, add = T)
```


Histogram of x



Cuantos más números aleatorios generemos, mejor será la aproximación:

```
set.seed(123)
x = round(rnorm(1000, 3, 1), 2)
hist(x, freq = F)
curve(dnorm(x, mean = 3, sd = 1), from = -2, to = 8, col = "blue", lwd = 2, add = T)
```

Histogram of x



3 Simulación de modelos de regresión

3.1 Simulación de valores condicionados

Vamos a estudiar el siguiente modelo de regresión:


$$Y = 2 + 0.25X + U$$

donde U es una variable aleatoria normal, $U \sim N(0, 1)$. Nosotros vamos a considerar que el regresor X toma los valores $X = [0, 2, 4, 6, 8, 10]$. Por tanto, no es variable aleatoria. En cambio, Y si es variable aleatoria debido a la presencia de U . Su valor dependerá del valor concreto que tome X . Esto se expresa matemáticamente escribiendo $Y|X = x_i$. Por las propiedades de la distribución normal (ver Apéndice: Propiedades de las variables aleatorias normales)

$$Y|X = x_i \sim N(2 + 0.25x_i, 1)$$

Vamos a comprobarlo mediante simulación. Primero vamos a simular el término de error, U :

```
set.seed(1)
u = rnorm(10000, 0, 1)
hist(u)
```




Y a continuación vamos a simular el valor de Y para $X = 3$

```
xi = 4
yi = 2 + 0.25*xi + u
```

Según lo visto anteriormente, para $X = 4$ se tendría que cumplir que $Y|X = 4 \sim N(2 + 0.25 * 4, 1)$.

```
hist(yi, freq = F, main = "Histograma de Y|X=4")
curve(dnorm(x, 2 + 0.3*xi, 1), col = "blue", lwd = 2, add = T)
```

Histograma de Y|X=4



La esperanza y la varianza se pueden calcular a partir de los valores simulados utilizando la **ley de los grandes números**:

$$\bar{y} = \frac{1}{N} \sum y_i \rightarrow E[Y|X = 4]$$

$$s_y^2 = \frac{1}{N-1} \sum (y_i - \bar{y})^2 \rightarrow Var[Y|X = 4]$$

```
# aproximación de 2 + 0.25*4
mean(yi)
```

```
## [1] 2.993463
```


```
# aproximación de 1
var(yi)
```

```
## [1] 1.024866
```

Para $X = 8$ se tiene $Y|X = 8 \sim N(2 + 0.25 * 8, 1)$:

```
xi = 8
yi = 2 + 0.25*xi + u
hist(yi, freq = F, main = "Histograma de Y|X=8")
curve(dnorm(x, 2 + 0.25*xi, 1), col = "blue", lwd = 2, add = T)
```

Histograma de $Y|X=8$




```
# aproximación de  $2 + 0.25 \cdot 8$   
mean(yi)
```

```
## [1] 3.993463
```

```
# aproximación de 1  
var(yi)
```

```
## [1] 1.024866
```

En el fondo, lo que tenemos es:



Por tanto, para cada valor x_i de X la variable $Y|X = x_i$ tiene distribución normal. Como se ha visto:

$$Y|X = x_i \sim N(2 + 0.25x_i, 1)$$

Este modelo se suele escribir también como

$$Y|x_i \sim N(2 + 0.25x_i, 1)$$

y también como

$$Y_i \sim N(2 + 0.25x_i, 1)$$

y por último como


$$Y_i = 2 + 0.25x_i + U_i, \quad U_i \sim N(0, 1)$$

En general, las variables aleatorias las escribiremos en mayúscula y los datos (obtenidos por simulación en este caso) en minúscula.

3.2 Simulación de conjuntos de puntos

En lugar de simular 1000 valores de Y para un valor concreto de X vamos a simular como máximo tres valores de Y para cada X (en principio podríamos simular tantos como queramos).

```
set.seed(1)
x = c(0,2,2,2,4,6,6,8,8,10)
u = rnorm(length(x))
y = 2 + 0.25*x + u
plot(x,y)
```




Pero a partir de estos puntos podemos estimar una recta utilizando mínimos cuadrados:

$$y_i = b_0 + b_1x_i + e_i$$

```
m = lm(y ~ x)
coefficients(m)
```

```
## (Intercept)          x
##  2.0181232    0.2737666
```

```
plot(x,y)
abline(m, col = "blue")
```



Como vemos, los valores calculados se parecen mucho a 2 y 0.25, ya que los datos simulados proceden de un modelo similar al estimado.

Si volvemos a simular los puntos

```
set.seed(2)
u = rnorm(length(x))
y = 2 + 0.25*x + u
m = lm(y ~ x)
coefficients(m)
```


```
## (Intercept)          x
##    1.796024    0.336485
```

Volvemos a obtener valores parecidos a 2 y 0.25. Veamos que ocurre si repetimos este proceso 1000 veces.


```
set.seed(1)
aa = rep(0,1000)
bb = rep(0,1000)
for (i in 1:1000){
  u = rnorm(length(x))
  y = 2 + 0.25*x + u
  m = lm(y ~ x)
  aa[i] = coef(m)[1]
  bb[i] = coef(m)[2]
}
```

```
hist(aa, freq = F)
```

Histogram of aa



```
hist(bb, freq = F)
```



Es decir, parece que tenemos dos variables aleatorias (recordad que variables aleatorias \rightarrow función de densidad, datos simulados \rightarrow histograma). Para verificar ésto, vamos a ver las ecuaciones con los que calculamos los valores de mínimos cuadrados:

$$\begin{bmatrix} b_0 \\ b_1 \end{bmatrix} = (X^T X)^{-1} (X^T y)$$

donde $y = [y_1 \ y_2 \ \dots \ y_{10}]^T$. El equivalente *teórico* de simular 1000 veces y obtener 1000 valores de b_0 y b_1 es considerar variables aleatorias Y_i en lugar de datos concretos y_i . Tenemos que:

$$Y_i \sim N(2 + 0.25x_i, 1), \ i = 1, 2, \dots, 10$$

En forma matricial, las 10 variables aleatorias se agrupan formando:

$$Y = \begin{bmatrix} Y_1 \\ Y_2 \\ \dots \\ Y_{10} \end{bmatrix} = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \dots & \dots \\ 1 & x_{10} \end{bmatrix} \begin{bmatrix} 2 \\ 0.25 \end{bmatrix} + \begin{bmatrix} U_1 \\ U_2 \\ \dots \\ U_{10} \end{bmatrix} \Rightarrow$$

$$Y \sim N(X\beta, I)$$

donde $\beta = [2 \ 0.25]^T$ e I es la matriz identidad de orden 10. Por tanto, teniendo en cuenta las propiedades de las distribuciones normales

$$(X^T X)^{-1} X^T Y \sim N(\beta, (X^T X)^{-1})$$

ya que

$$E[(X^T X)^{-1} X^T Y] = (X^T X)^{-1} X^T E[Y] = \beta$$

$$Var[(X^T X)^{-1} X^T Y] = (X^T X)^{-1} X^T Var[Y] X (X^T X)^{-1} = (X^T X)^{-1}$$


Es decir, si calculamos $(X^T X)^{-1}$:

```
X = cbind(rep(1,length(x)), x)
solve(t(X) %*% X)
```

```
##              x
## 0.33606557 -0.04918033
## x -0.04918033 0.01024590
```

entonces el histograma de *aa* corresponde a una $N(2,0.34)$ y el histograma de *bb* corresponde a una $N(0.25,0.10)$

```
hist(aa, freq = F)
curve(dnorm(x,2,sqrt(0.34)), add = T, col = "blue", lwd = 2)
```



```
hist(bb, freq = F)
curve(dnorm(x,0.25,sqrt(0.01)), add = T, col = "blue", lwd = 2)
```

Histogram of bb

